第六章　數據分析

焦點 1　集中趨勢的統計量

算術平均數	n 筆數據為 $x_1, x_2, \cdots, x_n$，則其**算術平均數**（簡稱為平均數）定義為 $\mu = \dfrac{x_1 + x_2 + \cdots + x_n}{n} = \dfrac{\sum_{i=1}^{n} x_i}{n}$ 。
加權平均數	對一組資料 $x_1, x_2, \cdots, x_n$，若 x_i 的權數為 f_i，$i = 1, 2, \cdots, n$，則此組資料的**加權平均數**為 $\mu = \dfrac{f_1x_1 + f_2x_2 + \cdots + f_nx_n}{f_1 + f_2 + \cdots + f_n} = \dfrac{\sum_{i=1}^{n} f_ix_i}{\sum_{i=1}^{n} f_i}$ 。
幾何平均數	1.對正整數 n，n 個正數 $x_1, x_2, \cdots, x_n$ 的**幾何平均數**為 $\sqrt[n]{x_1 \cdot x_2 \cdot \cdots \cdot x_n}$ 。 2.若 n 年的成長率分別為 $x_1, x_2, \cdots, x_n$，則這 n 年的**平均成長率**為 $\sqrt[n]{(1+x_1)\cdot(1+x_2)\cdot\cdots\cdot(1+x_n)} - 1$
中位數(Me)	所謂**中位數**是資料**由小到大排序**後，最中間的數或最中間兩個數的平均。所以大約有一半的數據小於或等於中位數，也大約有一半的數據大於或等於中位數，中位數以 Me 表示。
眾數(Mo)	資料中出現次數最多的資料稱為眾數，以 Mo 表示。 註：眾數可不唯一。
全距(R)	資料中的最大值減最小值所得之值稱為全距。
百分位數	(1)意義：當一群資料個數很多時，擴大中位數觀念，常用 99 個數將整群資料分成 100 等分稱這 99 個數為百分位數。 (2) 表示法：第 k 百分位數以 P_k 表示(k＝1 , 2 , 3 ,..., 99)，意即 P_k 是指這群資料的個數中，至少有 k%的資料小於或等於 P_k，且至少有(100－k)%的資料大於或等於 P_k。
百分位數的計算	(1)未分組資料：利用原始資料求第 k 百分位數 P_k 先將 n 個數據資料由小到大排序為 x_1，x_2，……，x_n， 令 $a = n \times k\%$ (i)若 a 是整數，則取第 a、(a＋1)個資料的平均值當作 $\dfrac{x_a + x_{a+1}}{2}$ 。 (ii)若 a 不是整數，取 a 的整數部分再加 1 令為 b，則取第 b 個資料得 $P_k = x_b$ (2)已分組資料：利用累積相對次數分配折線圖，約略找出百分位數 P_k 所代表的值。
四分位數	一群數據資料百分位數中的 P_{25}、P_{50}、P_{75}，別以 Q_1、Q_2、Q_3 表示，即 $Q_1 = P_{25}$、$Q_2 = P_{50}$、$Q_3 = P_{75}$(中文稱分別稱為第一、第二、第三 四分位數)而 $Q_2 = P_{50}$ 又稱為中位數。

焦點 2　分散程度的統計量

全距(R)	資料中的最大值減最小值所得之值稱為全距。
離差	將資料與平均數相減稱為離差以 $x_i-\mu$ 表示。
離差平方和(S_{xx})	離差平方和為 $S_{xx}=\sum_{i=1}^{n}(x_i-\mu)^2=\sum_{i=1}^{n}x_i^2-n\cdot\mu^2$
變異數與標準差	若一組數據 $x_1,x_2,\cdots,x_n$ 的算術平均數為 μ，則： 1.變異數 $\sigma^2=\dfrac{\sum_{i=1}^{n}(x_i-\mu)^2}{n}=\dfrac{S_{xx}}{n}$　2.標準差 $\sigma=\sqrt{\sigma^2}=\sqrt{\dfrac{S_{xx}}{n}}$ 。 3. $\sum_{i=1}^{n}x_i^2=n(\sigma^2+\mu^2)$ 註: $\sigma=\sqrt{\dfrac{\sum_{i=1}^{n}x_i^2-n\mu^2}{n}}=\sqrt{\dfrac{1}{n}\sum_{i=1}^{n}x_i^2-\mu^2}\,(\sqrt{方均-均方})$
標準差的性質	1.標準差可以以一組資料與平均數的平均距離去理解。 2.標準差愈大表示資料愈分散；反之愈小表示資料愈集中。 3.標準差 σ＝0，表示該組數據的每一個數值都相等。
平均數與標準差的符號	1.樣本平均用 $\bar{x}$ 母體平均用 μ 表示。 2.樣本標準差用 s 母體標準差用 σ 表示。 高中階段沒有樣本母體的差別，一律用 μ 表示平均，σ 表示標準差。

焦點 3　資料的伸縮平移與標準化資料

數的平移伸縮	若有兩組資料 x，y 滿足 $y=ax+b$，則： 1.算術平均數：$\mu_y=a\mu_x+b$ 2.中位數：$Me(y)=Me(ax+b)=a\times Me(x)+b$ 3.眾數：$Mo(y)=Mo(ax+b)=a\times Mo(x)+b$
差的平移與伸縮	若有兩組資料 x，y 滿足 $y=ax+b$，則： 1.全距：$R(y)=R(ax+b)=\lvert a\rvert\times R(x)$ 2.標準差：$\sigma(y)=\sigma(ax+b)=\lvert a\rvert\times\sigma(x)$
標準化資料	已知一組數據 $x_1,x_2,\cdots,x_n$ 的平均數為 μ_x，標準差為 σ_x。 $z_i=\dfrac{x_i-\mu_x}{\sigma_x},i=1,2,\cdots,n$，則 $z_1,z_2,\cdots,z_n$ 稱為數據 $x_1,x_2,\cdots,x_n$ 的標準化資料。
標準化資料性質	1.標準化之後的新數據，其算術平均數 $\mu_z=0$，且標準差 $\sigma_z=1$。 2.若將兩組數據都標準化後，即可對於這兩組數據作客觀的比較。

焦點 4　二維數據散布圖與相關係數

散布圖	觀察一組二維數據 (x_1, y_1)，(x_2, y_2)，…，(x_n, y_n) 之相關性，最直接的方法就是把數據標示在直角坐標平面上，形成 n 個散布的點，這樣的圖形稱為散布圖。
相關程度	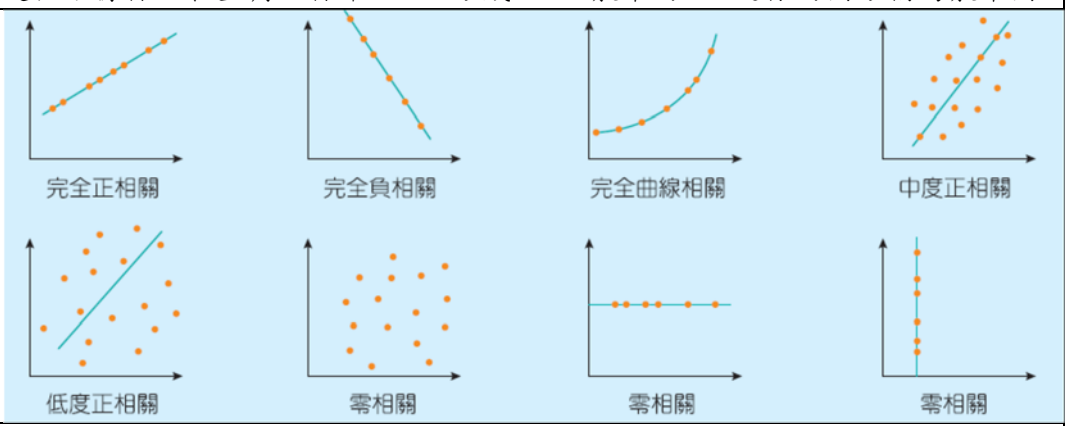
相關係數(r)	1.若 $\begin{cases} S_{xx}=\sum_{i=1}^{n}(x_i-\mu_x)^2=\sum_{k=1}^{n}x_i^2-n\mu_x^2 \\ S_{yy}=\sum_{i=1}^{n}(y_i-\mu_y)^2=\sum_{k=1}^{n}y_i^2-n\mu_y^2 \\ S_{xy}=\sum_{i=1}^{n}(x_i-\mu_x)(y_i-\mu_y)=\sum_{k=1}^{n}x_iy_i-n\mu_x\mu_y \end{cases}$ 則 $r=\dfrac{S_{xy}}{\sqrt{S_{xx}\cdot S_{yy}}}=\dfrac{S_{xy}}{n\sigma_x\sigma_y}$ 2. 設有 n 對標準化資料 $(x_1', y_1'), \cdots\cdots, (x_n', y_n')$ 的資料， 則 $r=\dfrac{x_1'y_1'+x_2'y_2'+\cdots+x_n'y_n'}{n}=\dfrac{\sum_{i=1}^{n}x_i'y_i'}{n}$ 3.若相關係數為 r，則 $-1\le r\le 1$。
相關係數的性質	已知 x, y 兩筆數據的相關係數為 r_{xy}，令 $u=ax+b,\ v=cy+d$，a,b,c,d 為任意常數，則 u,v 的相關係數 $r_{uv}=\begin{cases} r_{xy}, & a,c\text{同號} \\ -r_{xy}, & a,c\text{異號} \end{cases}$ 註：相關係數只顯現兩變數之間的線性關聯性強弱，**不能作成兩變數之間的推論**，即使兩個變量的相關係數很高，這兩個變量也不一定有因果關係，需要對整體(如數據)狀況有進一步的了解之後，才能下定論。

焦點 4　迴歸直線

最適直線(迴歸線)	當散布圖顯示出兩變量 X 與Y 間為直線相關時，希望找出一條「最適合代表兩變量之間關係的直線 L」稱為兩變量 X 與Y 的**最適直線**(或稱迴歸直線)，進而利用變數 X 來預測變數 Y 的值。
最小平方法	「最適合代表兩變量之間關係的直線 L」的求法很多種，考慮計算上的方便，採用由數學家高斯所提出的「**最小平方法**」。
最小平方法求迴歸線	(1)設迴歸直線 $L: y=mx+k$ ，將點 (x_i, y_i) 與點 (x_i, mx_i+k) 的距離 $\lvert y_i-(mx_i+k)\rvert$ ，如右圖稱為點 (x_i, y_i) 到直線 L 的**鉛垂線段長度**。 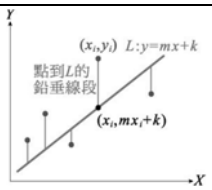 (2)計算此 n 個鉛垂線段長度的**平方和**之最小值，稱為**最小平方法**。
迴歸線的求法	由最小平方法得到 令 $y=a+bx$ 為迴歸線則： (1) (μ_x,μ_y) 必過迴歸線 $y=a+bx$ (2) $b=\dfrac{S_{xy}}{S_{xx}}$ 。 (3) $a=\mu_y-b\mu_x$
迴歸線 另一表示法	1. $y-\mu_y=b(x-\mu_x)$ 其中 $b=\dfrac{S_{xy}}{S_{xx}}=r\dfrac{\sigma_y}{\sigma_x}$ 。 2.設有 n 對標準化資料 $(x_1',y_1'),\cdots\cdots,(x_n',y_n')$ 的資料， 則迴歸直線為 $y'=bx'$ 。